Нерешенные проблемы и новые направления

Николай Анохин

26 марта 2022 г.

Контекст

Recommender Post-Processing
Validation
Spark
Offline Filters
Spark
Мы здесь
Recommender Model
Predictions
Models
Model Training
Spark
JSON
VR
Online Modules
Redis
Online Filters
Recommendation Service
elasticsearch
Recommendations
User Profile Service
Article Service
Events Service
Data Collection and Processing
Spark
Profiles
Articles
Events
Spark
Spark
Events (e.g. clicks, scrolls)
User Interface
Suggest, Email and Newsfeed
Recommendations

Что мы уже умеем

$$\hat{r}_{ui} = f_\theta(x_u, x_i, x_c)$$

Проблемы

1. Оцениваем айтемы по-отдельности, а показываем по несколько (лентой)
2. Модель не объясняет, почему именно эти айтемы подходят пользователю
3. Смещение между распределениями на обучении и применении
4. Не учитывается долгострочный эффект рекомендаций

Разнообразие в рекомендательных системах

Разнообразие / Diversity

Набираем айтемы с разными аспектами

f - аспект (признак) айтема, $p(f|i)$ – вероятность найти аспект у айтема i

Распределение аспекта у пользователя

$$p(f|u) = \frac{\sum_{i \in I_u} p(f|i)}{|I_u|}$$

Распределение аспекта в рекомендациях

$$q(f|u) = \frac{\sum_{i \in RL} p(f|i)}{|RL|}$$

Формируем список так, чтобы $q(f|u)$ совпало с $p(f|u)$

Жадное переранжирование

Добавляем в список рекомендаций айтем с максимальным значением

$$(1-\lambda)\cdot s(u,i)+\lambda\cdot gain(i,RL),$$

пока не получим список нужной длины.

- $s(u,i)$ – релевантность айтема i для пользователя u
- $gain(i,RL)=div(RL\cup\{i\})-div(RL)$ – улучшение разнообразия при добавлении айтема
- λ – гиперпараметр

A Comparison of Calibrated and Intent-Aware Recommendations [KB19]

Учим разнообразие вместе с моделью 1

Controllable Multi-Interest Framework for Recommendation [CZZ+20]

Учим разнообразие вместе с моделью 2

Managing Diversity in Airbnb Search [AHR+20]

Из-за поточечного предсказания релевантности, приходится дополнительно разнообразить списки рекомендаций

Необходимость разнообразия обосновывается A/B эесперименто

Объяснение рекомендаций

Объяснения

???

Объяснения

Потому что вы оценили Toy Story

Потому что вам нравятся комедии

Популярное

Зачем объяснять рекомендации?

1. Прозрачность: объяснить пользователю, как работает система
2. Контролируемость: позволить пользователю исправить ошибки
3. Доверие: убедить пользователя, что система работает правильно
4. Убеждение: мотивировать пользователя к покупке
5. Полезность: помочь пользователю принять правильное решение
6. Эффективность: помочь пользователю принять решение быстро
7. Удовольствие: сделать приятно пользователю

Case-based

Because you have selected or highly rated: Movie A

Collaborative

Customers Who Bought This Item Also Bought A

Content-based

Recommended because you said liked science fiction

Knowledge-based

Less Memory and Lower Resolution and Cheaper

This item Lenovo IdeaPad 3 14" Laptop, Intel Core i3-1005G1 Processor, 4GB DDR4 RAM, 128GB M.2 SSD Storage, 14.0" FHD (1920 x 1080) Display, Integrated Graphics, Windows 10 S, 81WD010QUS, Platinum Grey

#1 Best Seller

Add to Cart

Lenovo IdeaPad 3 14 Laptop, AMD Ryzen 5 5500U Processor, 8GB DDR4 RAM, 256GB NVMe TLC SSD Storage, 14.0" FHD (1920 x 1080) Display, AMD Radeon 7 Graphics, Windows 10 Home, 82KT00AMUS, Abyss Blue

Add to Cart

Lenovo IdeaPad 1 14 14.0" Laptop, 14.0" HD (1366 x 768) Display, Intel Celeron N4020 Processor, 4GB DDR4 RAM, 64 GB SSD Storage, Intel UHD Graphics 600, Win 10 in S Mode, 81VU0079US, Ice Blue Blue

Add to Cart

Lenovo IdeaPad Gaming 3 15 15.6" Laptop, 15.6" FHD (1920 x 1080) Display, AMD Ryzen 5 5600H Processor, NVIDIA GeForce GTX 1650, 8GB DDR4 RAM, 256GB SSD Storage, Windows 10H, 82K20015US, Shadow Black

Add to Cart

Customer Rating	★★★★☆ (32)	★★★★☆ (118)	★★★★½ (590)	★★★★½ (134)
Price	$399.00	$539.00	$266.42	$769.22
Sold By	eSales Plus	Xocean	Mohawk Shop	ETRON INC - ELECTRONICS SUPPLIER
Computer Memory Size	128 GB	8	4	8
CPU Model Manufacturer	Intel	AMD	Intel	AMD
CPU Speed	1.2 GHz	2.1	1.1	3.3

Explore, Exploit, and Explain: Personalizing Explainable Recommendations with Bandits [MLH+18]

Explanation	# Impressions
Because it's [day of week]	140.3K
Inspired by [user]'s recent listening	138.4K
Because it's a new release	140.5K
Because [user] likes [genre]	130.7K
Because it's popular	140.5K
Mood	140.7K
Focus	140.5K

$$r(j, e, x) = \sigma(\theta_{global} + \theta_j \times 1_j + \theta_e \times 1_e + \theta_x \times 1_x)$$

Why I like it: Multi-task Learning for Recommendation and Explanation [LDS18]

Если хотим делать объяснения рекомендаций, нужно ответить на вопросы:

- Какую цель мы достигнем объяснениями?
- Какие объяснения можно получить из модели?
- Как правильно представить объяснения пользователю?

Смещения

Удачные рекомендации

Пример self-selection bias

Figure 1. Movie-Lovers toy example. Top row: true rating matrix Y, propensity matrix P, observation indicator matrix O. Bottom row: two rating prediction matrices $\hat{Y}_1$ and $\hat{Y}_2$, and intervention indicator matrix $\hat{Y}_3$.

$$R(\hat{Y}) = \frac{1}{UI}\sum_u \sum_i \delta_{ui}(Y, \hat{Y}), \quad R_{naive}(\hat{Y}) = \frac{1}{N}\sum_{(u,i)\in D} \delta_{ui}(Y, \hat{Y})$$

Смещения в рекомендациях [Jar19]

Inverse Propensity Scored Estimator [SSS+16]

$P_{ui} = P((u,i) \in D)$ – вероятность, что пользователь u поставит оценку айтему i

$$R_{IPS}(\hat{Y}|P) = \frac{1}{UI} \sum_{(u,i)\in D} \frac{\delta_{ui}(Y,\hat{Y})}{P_{ui}}$$

$$E_D[R_{IPS}(\hat{Y}|P)] = \frac{1}{UI} \sum_u \sum_i E_D \left[\frac{\delta_{ui}(Y,\hat{Y})}{P_{ui}} \mathbb{I}\{(u,i) \in D\} \right] =$$

$$= \frac{1}{UI} \sum_u \sum_i \delta_{ui}(Y,\hat{Y}) = R(\hat{Y})$$

IPS Estimator: проблемы

1. Когда P_{ui} неизвестно, его приходится оценивать
2. Большая дисперсия при оценке P_{ui}
3. Непонятно, как быть с рекомендациями списков

Causal рекомендации

Традиционный рекомендер

Посмотрит ли пользователь этот фильм, если известно что она смотрела в прошлом?

Causal рекомендер

Посмотрит ли пользователь этот фильм, если мы его порекомендуем, и известно, что она смотрела в прошлом?

The Deconfounded Recommender [WLCB18]

Confounder

Переменная, которая влияет и на treatment assignment, и на outcome

1. Учим модель $p(z, a_1, \ldots, a_m)$
2. Оцениваем $E(z_j | a_{1j}, \ldots, a_{mj})$ для каждого наблюдения
3. Используем оценки для z_j как признак в рекомендере

(a) Probabilistic MF **(b)** Poisson MF **(c)** Weighted MF

Из-за специфики сбора данных рекомендации подвержены смещениям.

Существуют техники для корректировки, но они несовершенны.

Итоги

Итоги

При построении моделей мы делаем упрощающие предположения. Из-за этих предположений в продакшен системах могут возникать негативные эффекты. Эти эффекты нужно учитывать и пытаться исправить.

Литература I

- Mustafa Abdool, Malay Haldar, Prashant Ramanathan, Tyler Sax, Lanbo Zhang, Aamir Manaswala, Lynn Yang, Bradley Turnbull, Qing Zhang, and Thomas Legrand, *Managing diversity in airbnb search*, Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (New York, NY, USA), KDD '20, Association for Computing Machinery, 2020, p. 2952–2960.
- Yukuo Cen, Jianwei Zhang, Xu Zou, Chang Zhou, Hongxia Yang, and Jie Tang, *Controllable multi-interest framework for recommendation*, Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (2020).
- Greg Jarboe, *Understanding biases in search and recommender systems*, 2019.

Литература II

- Mesut Kaya and Derek Bridge, *A comparison of calibrated and intent-aware recommendations*, Proceedings of the 13th ACM Conference on Recommender Systems (New York, NY, USA), RecSys '19, Association for Computing Machinery, 2019, p. 151–159.
- Yichao Lu, Ruihai Dong, and Barry Smyth, *Why i like it: Multi-task learning for recommendation and explanation*, Proceedings of the 12th ACM Conference on Recommender Systems (New York, NY, USA), RecSys '18, Association for Computing Machinery, 2018, p. 4–12.
- James McInerney, Benjamin Lacker, Samantha Hansen, Karl Higley, Hugues Bouchard, Alois Gruson, and Rishabh Mehrotra, *Explore, exploit, and explain: Personalizing explainable recommendations with bandits*, Proceedings of the 12th ACM Conference on Recommender Systems (New York, NY, USA), RecSys '18, Association for Computing Machinery, 2018, p. 31–39.

Литература III

- Tobias Schnabel, Adith Swaminathan, Ashudeep Singh, Navin Chandak, and Thorsten Joachims, *Recommendations as treatments: Debiasing learning and evaluation*, Proceedings of the 33rd International Conference on International Conference on Machine Learning - Volume 48, ICML'16, JMLR.org, 2016, p. 1670–1679.
- Yixin Wang, Dawen Liang, Laurent Charlin, and David M. Blei, *The deconfounded recommender: A causal inference approach to recommendation*, ArXiv **abs/1808.06581** (2018).